TCC1 - Classificacao da Qualidade da Agua

1. Objetivo

Implementar e avaliar modelos de Machine Learning para classificar se uma amostra de agua e potavel ou nao, usando dados fisico-quimicos ambientais.

2. Dataset

Nome: Water Quality / Water Potability (Kaggle)

Total de amostras: 3.276 | Features: 9 | Alvo: Potability (0 = Nao Potavel, 1 = Potavel)

Distribuicao: 1.998 Nao Potavel (61%) / 1.278 Potavel (39%)

Valores ausentes: ph (491), Sulfate (781), Trihalomethanes (162) preenchidos com a media da coluna.

3. Pipeline

1. Carregar o dataset
2. Preencher valores ausentes com a media
3. Dividir em treino (80%) e teste (20%)
4. Aplicar SMOTE no conjunto de treino
5. Normalizar com StandardScaler
6. Treinar os modelos
7. Avaliar no conjunto de teste

4. Balanceamento com SMOTE

O dataset e desbalanceado. Sem correcao, modelos simples ignoram a classe minoritaria. SMOTE cria amostras sinteticas da classe minoritaria interpolando entre vizinhos proximos. Resultado: ambas as classes ficam com 1.598 amostras no treino. Regra fundamental: SMOTE e aplicado somente no treino, nunca no teste.

5. Modelos Implementados

Naive Bayes (GaussianNB): baseado no Teorema de Bayes. Assume independencia entre as features.

Regressao Logistica: calcula combinacao linear das features e aplica a funcao sigmoide. Assume fronteira linear entre as classes.

6. Resultados

Modelo | Acuracia | Precisao | Recall | F1-Score | AUC-ROC Naive Bayes | 0.5808 | 0.4652 | 0.4961 | 0.4802 | 0.5949 Regressao Logistica | 0.5213 | 0.4076 | 0.5000 | 0.4491 | 0.5279

7. Conclusao

AUC-ROC de 0.59 (Naive Bayes) e 0.52 (Regressao Logistica) mostram que modelos lineares sao insuficientes para classificar a potabilidade da agua. Isso justifica o uso de MLP (Multilayer Perceptron) no TCC 2, capaz de aprender relacoes nao-lineares entre os parametros fisico-quimicos.